

Efeito do Ruído no Gradiente em Mecanismos de Atenção para Tradução Automática Neural

Nicole Maia Argondizzi¹, Marcelo Keese Albertini²,
Pedro Henrique Bernardes Caetano Milken¹, Isaac Miranda Camargos³

¹Programa de Pós-Graduação em Ciência da Computação (PPGCO)
Universidade Federal de Uberlândia (UFU) – Uberlândia – MG – Brasil

²Faculdade de Computação (FACOM)
Universidade Federal de Uberlândia (UFU) – Uberlândia – MG – Brasil

³Pesquisador e profissional da área de Computação (sem vínculo institucional)

{nicole.argondizzi, pedrohbcacetano, albertini}@ufu.br, isaacmirandacamargos@gmail.com

Abstract. *This paper investigates the effect of Gaussian gradient noise on five attention mechanism families for Neural Machine Translation (NMT) in the English-French (EN→FR) direction: Scaled Dot-Product Attention, Dense Synthesizer, Factorized Dense Synthesizer, Factorized Random Synthesizer, and Luong General Attention. All models share the same Transformer architecture ($d_{model} = 512$, $L = 6$, $h = 8$), dataset ($\sim 685k$ EN→FR pairs), and training protocol, varying only the attention score function and the presence of decaying Gaussian noise applied after gradient clipping (fifteen configurations total). Results show that gradient noise benefits four of the five mechanisms: Scaled Dot-Product achieves the best absolute SacreBLEU (22.90, +21.1%), Dense Synthesizer obtains the largest relative gain (19.51, +120.4%), and Luong General Attention, which collapses without noise (0.47 BLEU), reaches 17.51 with it. Critically, Factorized Random Synthesizer is the sole counterexample where noise consistently degrades performance (5.45, -44.7%), demonstrating that the benefit of gradient perturbation depends on whether the score function has trainable parameters capable of benefiting from exploration.*

Resumo. *Este artigo investiga o efeito do ruído Gaussiano no gradiente sobre cinco famílias de mecanismos de atenção para tradução automática neural (NMT) no par EN→FR: Scaled Dot-Product Attention, Dense Synthesizer, Factorized Dense Synthesizer, Factorized Random Synthesizer e Luong General Attention. Todos os modelos compartilham a mesma arquitetura Transformer ($d_{model} = 512$, $L = 6$, $h = 8$), conjunto de dados (~ 685 mil pares) e protocolo de treinamento, variando apenas a função de score e a presença de ruído Gaussiano com variância decrescente após o gradient clipping (quinze configurações). Os resultados mostram que o ruído beneficia quatro dos cinco mecanismos: Scaled Dot-Product atingiu o melhor SacreBLEU absoluto (22,90, +21,1%), Dense Synthesizer obteve o maior ganho relativo (19,51, +120,4%) e Luong General, inviável sem ruído (0,47 BLEU), alcançou 17,51 com ele. O Factorized Random Synthesizer é o único contraexemplo: o ruído degrada seu desempenho em -44,7%, demonstrando que o benefício da perturbação é condicionado pela estrutura treinável da função de score.*

Introdução

A tradução automática neural (NMT) experimentou um salto qualitativo com a introdução dos mecanismos de atenção. Antes deles, modelos encoder-decoder comprimiam toda a informação da sentença-fonte em um único vetor de contexto de dimensão fixa — uma representação claramente insuficiente para sentenças longas. [Bahdanau et al. 2015] resolveram esse gargalo ao propor o *alinhamento soft*: em vez de um vetor único, o decodificador atribui, a cada passo de geração, um peso diferente a cada posição do codificador via uma rede neural aditiva. Isso permitiu que o modelo consultasse dinamicamente quais partes da entrada eram mais relevantes para cada token gerado, melhorando substancialmente a qualidade em pares linguísticos longos.

Embora eficaz, a atenção aditiva de Bahdanau era computacionalmente cara. [Luong et al. 2015] propuseram formulações alternativas mais eficientes, entre elas a atenção *general*: $\text{score}(h_t, h_s) = h_t^\top W_a h_s$, onde h_t é o estado do decodificador, h_s o do codificador e W_a uma projeção aprendida. Essa abordagem multiplicativa reduz o custo computacional mantendo a capacidade de capturar dependências entre posições.

O passo seguinte foi eliminar a própria recorrência. [Vaswani et al. 2017] propuseram o Transformer, no qual toda a codificação e decodificação ocorre por meio de camadas de *Scaled Dot-Product Attention* paralelizáveis:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V,$$

onde Q , K e V são projeções lineares da entrada e $\sqrt{d_k}$ normaliza os scores. Ao processar toda a sequência de uma vez, o Transformer captura dependências de longo alcance com muito mais eficiência que arquiteturas recorrentes, tornando-se a arquitetura dominante em NMT moderna.

Com o Transformer estabelecido, uma questão natural emergiu: o produto escalar entre *queries* e *keys* é realmente necessário? [Tay et al. 2021] responderam com os Synthesizers: três mecanismos que dispensam o produto $QK^\top$ em favor de alternativas radicalmente diferentes. O *Dense Synthesizer* substitui esse produto por uma rede neural de duas camadas aplicada à própria representação de entrada, sem interação explícita entre pares de tokens. O *Factorized Dense Synthesizer* vai além e fatora a matriz de scores de posto baixo, reduzindo o custo paramétrico. O *Factorized Random Synthesizer* leva a radicalidade ao extremo: usa pesos de atenção fixos e aleatórios, completamente independentes dos dados — e ainda assim obtém desempenho razoável.

Em paralelo, a literatura de otimização de redes profundas identificou no *ruído do gradiente* uma técnica de regularização pouco explorada em NMT. [Neelakantan et al. 2016] demonstraram que adicionar ruído Gaussiano de variância decrescente

$$\sigma_t^2 = \frac{\eta}{(1+t)^\gamma}$$

diretamente ao gradiente melhora a generalização em redes profundas. Nessa equação, σ_t^2 é a *variância* do ruído no passo de otimização t ; η define a *amplitude inicial* (quanto maior η , mais intensa a perturbação no começo); t é o *número acumulado de passos* desde o início do treinamento; e γ é o *expoente de decaimento*, que controla a velocidade

com que o ruído diminui. À medida que t cresce, o denominador $(1+t)^\gamma$ aumenta e σ_t^2 decresce: a perturbação é grande no início — facilitando a fuga de mínimos locais rasos e pontos de sela — e pequena ao final, permitindo convergência estável.

Apesar do interesse científico em ambas as direções — diversificação das funções de score e regularização por ruído de gradiente — a interação entre esses dois eixos permanece não investigada sistematicamente. Não está claro se o benefício do ruído é universal entre mecanismos de atenção distintos, ou se depende da geometria da paisagem de perda induzida por cada função de score.

Contribuição. Este trabalho apresenta um estudo controlado do efeito do ruído Gaussiano no gradiente sobre cinco mecanismos de atenção (*Scaled Dot-Product* [Vaswani et al. 2017], *Dense Synthesizer*, *Factorized Dense Synthesizer*, *Factorized Random Synthesizer* [Tay et al. 2021] e *Luong General Attention* [Luong et al. 2015]), em quinze configurações com a mesma arquitetura Transformer ($d_{\text{model}} = 512$, $L = 6$, $h = 8$) e conjunto de dados (~ 685 mil pares EN $\rightarrow$ FR). Os resultados mostram que o benefício da perturbação é condicionado pela estrutura de cada mecanismo: quatro obtêm ganhos de +14,7% a +120,4% em SacreBLEU; o *Factorized Random Synthesizer* é o único contraexemplo (−44,7%); e o *Luong General*, inviável sem ruído (0,47 BLEU), atinge 17,51 com ele.

Trabalhos Relacionados

A evolução dos trabalhos que fundamentam este estudo segue dois eixos complementares: o aperfeiçoamento da função de score de atenção (Bahdanau 2015 $\rightarrow$ Luong 2015 $\rightarrow$ Transformer 2017 $\rightarrow$ Synthesizers 2021) e a regularização por ruído de gradiente (Neelakantan 2016). As seções seguintes detalham cada contribuição.

Mecanismos de Atenção em NMT

A atenção aditiva de [Bahdanau et al. 2015] e a multiplicativa de [Luong et al. 2015] estabeleceram que o alinhamento dinâmico entre codificador e decodificador é fundamental para a qualidade de tradução. A formulação *general* de Luong — $\text{score}(h_t, h_s) = h_t^\top W_a h_s$ — requer estados explícitos de decodificador, limitando o uso em arquiteturas completamente paralelas.

[Vaswani et al. 2017] superaram essa limitação com o Transformer: ao substituir a recorrência por *multi-head scaled dot-product attention*, permitiram processamento paralelo de seqüências inteiras e captura eficiente de dependências de longo alcance.

[Tay et al. 2021] questionaram se o produto $QK^\top$ é essencial, propondo três alternativas. O *Dense Synthesizer* substitui $QK^\top$ por uma MLP de duas camadas; o *Factorized Dense* fatoriza a matriz de scores em projeções de posto baixo; e o *Factorized Random* usa pesos aleatórios fixos. Em inglês-alemão (WMT), o *Dense Synthesizer* alcançou 27,43 BLEU, competitivo com o Transformer padrão (27,45), sugerindo flexibilidade arquitetural considerável na função de score.

[Bhojanapalli et al. 2020] identificaram um gargalo de posto baixo (*low-rank bottleneck*) inerente à atenção multi-cabeça, motivando mecanismos fatorados [Tay et al. 2022]. Padrões fixos no codificador também foram explorados por [Raganato et al. 2020], que demonstraram que certos cabeçotes podem ser substituídos

por padrões predefinidos sem degradação significativa — achado conceitualmente próximo ao *Factorized Random Synthesizer*.

Ruído no Gradiente como Regularizador

[Neelakantan et al. 2016] demonstraram que adicionar ruído Gaussiano de variância decrescente $\sigma_t^2 = \eta/(1+t)^\gamma$ ao gradiente melhora a generalização em redes profundas, especialmente em treinamentos longos com paisagens de perda acidentadas. Esta técnica distingue-se do decaimento de pesos via AdamW [Loshchilov and Hutter 2019]: em vez de reduzir a magnitude dos parâmetros, ela perturba diretamente a *direção* do descenso, promovendo exploração do espaço de parâmetros durante a otimização.

Lacuna de Pesquisa

Enquanto o efeito do ruído de gradiente é bem documentado em redes convolucionais e recorrentes, sua interação com diferentes *funções de score de atenção* não foi avaliada sistematicamente. Permanece em aberto se mecanismos com geometrias de paisagem de perda distintas — como a MLP do Dense Synthesizer versus os pesos fixos do Random Synthesizer — respondem de maneira diferente à perturbação. Esta é a lacuna que o presente trabalho aborda.

Metodologia

Mecanismos de Atenção Investigados

A atenção multi-cabeça é formulada de forma unificada como

$$\text{MultiHead}(X) = \text{Concat}(\text{head}_1, \dots, \text{head}_h) W^O, \quad \text{head}_i = \text{softmax}\left(\frac{\text{score}_i(X)}{\sqrt{d_k}}\right) X W_i^V,$$

onde X são as representações de entrada, W^O a projeção de saída, e cada cabeça computa atenção ponderando as projeções de valores $X W_i^V$ pelos scores normalizados; a diferença entre os cinco mecanismos reside exclusivamente em $\text{score}_i(\cdot)$. A Tabela 1 resume as cinco funções de score e suas contagens totais de parâmetros.

Tabela 1. Resumo das cinco funções de score investigadas. *Par.*: total de parâmetros do modelo em milhões. Mecanismos 1–3 e 5 produzem distribuições de atenção dinâmicas (dependentes da entrada); o mecanismo 4 é completamente estático.

#	Mecanismo	Função de score	Par. (M)
1	Scaled Dot-Product	$(XW_Q)(XW_K)^\top / \sqrt{d_k}$	77,44
2	Dense Synthesizer	$W_2(\text{ReLU}(W_1 X))$	82,19
3	Factorized Dense Synth.	$H_a(F_a(X)) \odot H_b(F_b(X)), a \times b = N$	69,78
4	Factorized Random Synth.	$R \in \mathbb{R}^{N \times N}$ (fixo, aleatório)	68,30
5	Luong General	$h_t^\top W_a h_s$ (h_t : decoder; h_s : encoder)	77,51

Os cinco mecanismos diferem apenas em $\text{score}_i(\cdot)$: **(1) Scaled Dot-Product** usa o produto escalar entre as projeções aprendidas $Q=XW_Q$ e $K=XW_K$, atenção padrão do Transformer [Vaswani et al. 2017]. **(2) Dense Synthesizer** substitui $QK^\top$ por uma

MLP de duas camadas aplicada à própria representação de entrada (W_1, W_2), eliminando a interação explícita entre pares de tokens [Tay et al. 2021]. **(3) Factorized Dense** fatora a matriz de scores $N \times N$ como produto elemento-a-elemento de duas projeções de baixa dimensão ($a=b=11$ para $N=128$), reduzindo parâmetros [Tay et al. 2021]. **(4) Factorized Random** usa pesos R inicializados aleatoriamente e mantidos fixos — apenas as projeções de valor V são treinadas, testando o limite inferior de expressividade [Tay et al. 2021]. **(5) Luong General** computa atenção cruzada entre o estado do decodificador h_t e os estados do codificador h_s via projeção aprendida W_a [Luong et al. 2015], adaptada à configuração multi-cabeça.

Arquitetura e Protocolo de Treinamento

Todos os modelos utilizam a mesma arquitetura Transformer: $d_{\text{model}} = 512$, $L_{\text{enc}} = L_{\text{dec}} = 6$, $h = 8$, $d_k = 64$, $d_{\text{ff}} = 2048$, $\text{dropout}=0,1$ [Srivastava et al. 2014], *weight tying* e RMSNorm. O vocabulário é SentencePiece de 65k tokens [Sennrich et al. 2016] com comprimento máximo de sequência $N = 128$.

O treinamento utiliza AdamW [Loshchilov and Hutter 2019] ($lr = 3 \times 10^{-4}$, $\text{weight decay}=0,01$), escalonamento OneCycleLR, $\text{batch size}=32$, $\text{label smoothing}=0,1$ [Szegedy et al. 2016] e *gradient clipping* com norma máxima 1,0. O *early stopping* com paciência de 3 épocas previne estagnação prolongada. Todas as configurações foram avaliadas por até 100 épocas. Para Scaled Dot-Product e Dense Synthesizer, resultados intermediários em 30 épocas são adicionalmente reportados para análise da trajetória de convergência. Configurações com ruído foram avaliadas exclusivamente em 100 épocas.

Protocolo de Ruído no Gradiente

Após o *gradient clipping*, ruído Gaussiano é adicionado a cada parâmetro a cada 10.000 passos de otimização:

$$g_t \leftarrow g_t + \varepsilon_t, \quad \varepsilon_t \sim \mathcal{N}(0, \sigma_t^2), \quad \sigma_t^2 = \frac{\eta}{(1+t)^\gamma},$$

com $\eta = 0,3$ e $\gamma = 0,55$, seguindo [Neelakantan et al. 2016].

Cada elemento da equação de variância desempenha papel específico: σ_t^2 é a *variância* do ruído Gaussiano adicionado ao gradiente no passo t — quanto maior σ_t^2 , maior a perturbação; η define a *amplitude inicial* (em $t=0$, $\sigma_0^2 = \eta$ e $\sigma_0 \approx 0,55$); t é o *passo de otimização acumulado*; e γ é o *expoente de decaimento* que controla a velocidade com que o ruído diminui — valores maiores de γ aceleram o decaimento. À medida que t cresce, o denominador $(1+t)^\gamma$ aumenta e σ_t^2 decresce continuamente, implementando um *currículo de ruído*: perturbação intensa nas épocas iniciais (facilitando a fuga de mínimos rasos) seguida de refinamento estável ao final ($\sigma_{200k} \approx 0,02$ após ~ 200 mil passos).

Spikes de gradiente foram detectados via limiar adaptativo por época: $T_e = \mu_e + 3\sigma_e$, onde μ_e e σ_e são a média e o desvio padrão da norma ℓ_2 do gradiente naquela época. Um *spike* é contado quando a norma ultrapassa T_e por pelo menos 10 unidades absolutas, evitando falsos positivos em treinamentos com gradientes geralmente baixos.

Dados e Avaliação

Utilizou-se combinação de quatro corpus paralelos EN→FR: *opus100* [Zhang et al. 2020], *opus_books*, *WMT 2014* [Bojar et al. 2014] e *Europarl* [Koehn 2005]. Após filtragem (mínimo 3 palavras, máximo 120 palavras, similaridade máxima entre pares de 60% pelo método *SequenceMatcher*), o conjunto totaliza ~685 mil pares, divididos em 80% treino, 10% validação e 10% teste.

A avaliação de qualidade de tradução usa SacreBLEU [Papineni et al. 2002] em nível de corpus sobre o conjunto de teste. Hardware: GPU única NVIDIA com CUDA 12.6 e PyTorch 2.1.

Resultados

A Tabela 2 apresenta as métricas das principais configurações experimentais. Para cada mecanismo, os resultados sem ruído servem de linha de base; a melhor configuração com ruído é destacada em negrito. A coluna Δ indica a variação relativa de SacreBLEU em relação à melhor configuração sem ruído de cada mecanismo.

Tabela 2. Métricas comparativas — tradução EN→FR. PPL: perplexidade no conjunto de teste; Spk.: anomalias de norma de gradiente detectadas em 100 épocas; Inf.: tempo de inferência em segundos sobre o conjunto de teste; Δ : variação relativa de SacreBLEU frente à linha de base sem ruído do mesmo mecanismo (“—” nas linhas de referência).

Mecanismo	Config.	BLEU	PPL	Spk.	Par. (M)	Inf. (s)	Δ
<i>Scaled Dot-Prod.</i>	100ep, s/ruído	18,91	24,2	331	77,44	19,7	—
	100ep, $\sigma=0,10$	22,90	24,5	24	77,44	18,6	+21,1%
<i>Dense Synth.</i>	100ep, s/ruído	8,85	93,5	177	82,19	17,7	—
	100ep, $\sigma=0,10$	19,51	33,9	12	82,19	16,7	+120,4%
<i>Fact. Dense Synth.</i>	100ep, s/ruído	6,38	64,5	12	69,78	17,8	—
	100ep, $\sigma=0,10$	7,32	65,1	5	69,78	17,4	+14,7%
<i>Fact. Random Synth.</i>	100ep, s/ruído	9,85	59,0	18	68,30	14,9	—
	100ep, $\sigma=0,10$	5,45	67,4	2	68,30	15,8	−44,7%
<i>Luong General</i>	100ep, s/ruído	0,47	544,2	575	77,51	20,3	—
	100ep, $\sigma=0,10$	17,51	24,2	20	77,51	20,1	+3625,5%

A Figura 1 sintetiza visualmente os resultados em 100 épocas, contrastando o desempenho sem e com ruído para cada mecanismo.

Scaled Dot-Product. Sem ruído em 100 épocas, o modelo atinge 18,91 SacreBLEU com 331 *spikes* de gradiente — sinal de instabilidade crescente. Com ruído ($\sigma = 0,10$), o modelo atinge 22,90 SacreBLEU, o melhor resultado absoluto do experimento com esse nível de ruído, com redução de 92,7% nos *spikes* (331→24). O ruído atua, portanto, como mecanismo de controle do *overfitting* em treinamentos longos, permitindo que o modelo explore uma região maior e de melhor qualidade do espaço de parâmetros.

Dense Synthesizer. Este mecanismo exhibe o comportamento mais revelador do experimento: sem ruído, o BLEU *piora* sistematicamente com mais treinamento (11,17




Figura 1. Comparação de SacreBLEU por mecanismo em 100 épocas: barras claras indicam a configuração sem ruído; barras escuras, a melhor configuração com ruído. Para o *Luong General* sem ruído, o modelo converge para um mínimo trivial (0,47 SacreBLEU). O *Factorized Random Synthesizer* é o único mecanismo prejudicado pelo ruído (−44,7%).

em 30 épocas $\rightarrow$ 8,85 em 100 épocas), acompanhado por 177 *spikes* — padrão típico de divergência progressiva. Com ruído ($\sigma = 0,10$), obtém o maior ganho relativo do estudo (+120,4%), alcançando 19,51 SacreBLEU com 12 *spikes* e o menor tempo de inferência (16,7s). A MLP de score beneficia-se enormemente da exploração induzida pelo ruído.

Factorized Dense Synthesizer. Também se beneficia do ruído (+14,7%), mas o SacreBLEU final de 7,32 permanece muito abaixo dos demais mecanismos. A fatorização $a \times b = N$ ($a = b = 11$) impõe uma restrição de posto baixo que limita estruturalmente a capacidade expressiva do score. A redução de 12 para 5 *spikes* (−58,3%) confirma o efeito regularizador, mas o ganho de BLEU modesto indica que o ruído não supera o teto de qualidade imposto pela fatorização.

Factorized Random Synthesizer. Contraexemplo fundamental: é o único mecanismo em que o ruído *prejudica* o desempenho. Sem ruído, o modelo atinge 9,85 SacreBLEU em 100 épocas. Com ruído ($\sigma = 0,10$), o BLEU cai para 5,45 (−44,7%) e a perplexidade sobe de 59,0 para 67,4. Como os pesos de atenção são fixos, o único aprendizado ocorre nas projeções de valor V , que são desestabilizadas pelo ruído sem a contrapartida de explorar melhor alinhamento. Este resultado demonstra que o benefício do ruído depende de haver graus de liberdade treináveis na função de score.

Luong General. Sem ruído, o mecanismo converge para um mínimo trivial durante o treinamento (0,47 SacreBLEU, perplexidade 544,2), indicando que o otimizador fica preso em uma região degenerada do espaço de parâmetros. Com ruído ($\sigma = 0,10$), já em 30 épocas atinge 11,40 SacreBLEU; em 100 épocas, 17,51 (perplexidade 24,2) — competitivo com o Scaled Dot-Product sem ruído (18,91). Para este mecanismo, a perturbação é uma condição necessária para treinamento viável.

Sensibilidade ao Nível de Ruído

A Figura 2 apresenta a sensibilidade do Scaled Dot-Product ao nível de ruído σ em 30 e 100 épocas de treinamento.




Figura 2. SacreBLEU em função do nível de ruído σ para o Scaled Dot-Product. Linha sólida: 30 épocas; linha tracejada: 100 épocas (apenas três configurações avaliadas). A linha vertical pontilhada em $\sigma = 0,01$ marca o ponto ótimo identificado.

Dois padrões emergem claramente. Primeiro, **ruído pequeno ajuda, ruído grande prejudica**: para 30 épocas, valores de $\sigma \leq 0,01$ produzem ganhos marginais (+1,3%), enquanto $\sigma = 1,0$ colapsa o BLEU para 11,79 (−38,2% em relação à linha de base). Segundo, o **tempo de treinamento amplia o benefício**: enquanto $\sigma = 0,01$ melhora apenas +1,3% em 30 épocas, o mesmo nível de ruído em 100 épocas produz +23,3%. Isso sugere que o ruído precisa de múltiplas rodadas de treinamento para acumular seus efeitos de navegação na paisagem de perda.

Efeito Regularizador sobre Spikes de Gradiente

A Figura 3 quantifica a redução de *spikes* de gradiente com ruído para os três mecanismos com dados disponíveis.

O ruído reduz os *spikes* em todos os três mecanismos avaliados: −92,7% no Scaled Dot-Product (331→24), −93,2% no Dense Synthesizer (177→12) e −58,3% no Factorized Dense (12→5). A correlação entre redução de *spikes* e ganho de BLEU é consistente com a hipótese de que a instabilidade de gradiente é um indicador de mínimos locais subotimais: ao suavizar a trajetória de otimização, o ruído não apenas estabiliza o treinamento, mas permite acesso a regiões de melhor generalização.

Discussão

Os cinco mecanismos investigados respondem ao ruído de gradiente de maneiras fundamentalmente distintas, e essa diversidade não é acidental: ela reflete diretamente a geometria da paisagem de perda imposta por cada função de score. Discutimos abaixo os padrões mais significativos e suas implicações.




Figura 3. Número de *spikes* de gradiente detectados em 100 épocas, sem e com ruído ($\sigma = 0,10$). As porcentagens indicam a redução relativa. *Scaled Dot-Product* e *Dense Synthesizer* apresentam reduções superiores a 92%, consistentes com ganhos de BLEU expressivos.

Função de Score, Paisagem de Perda e Pontos de Sela

O achado central deste estudo é que **o benefício do ruído de gradiente está condicionado à estrutura da paisagem de perda induzida pela função de score**. Mecanismos cujos pesos de score criam paisagens complexas e acidentadas — com pontos de sela e mínimos locais frequentes — beneficiam-se dramaticamente da perturbação (Dense Synthesizer: +120,4%; Luong General: de 0,47 para 17,51). Mecanismos já bem comportados (Scaled Dot-Product) beneficiam-se moderadamente (+23,3%). Mecanismos com pesos fixos (Factorized Random), por outro lado, são prejudicados (−44,7%), pois o ruído perturba os únicos parâmetros treináveis (as projeções de valor) sem oferecer qualquer benefício de exploração.

Em espaços de alta dimensão — como os 77–82 milhões de parâmetros dos modelos avaliados — pesquisas recentes indicam que **pontos de sela** são estruturalmente mais prevalentes que mínimos locais [Dauphin et al. 2014]. Um ponto de sela possui gradiente nulo mas não é um mínimo: em algumas direções a perda cresce e em outras decresce. O otimizador tende a desacelerar ao se aproximar de um ponto de sela e pode ficar preso indefinidamente em sua vizinhança, mesmo sem gradiente nulo, se a região de planura for extensa. O ruído de gradiente atua precisamente neste cenário: a perturbação aleatória desloca o otimizador para fora das direções de curvatura quase nula, permitindo que ele encontre direções de descenso produtivo.

O caso do *Dense Synthesizer* é particularmente elucidativo. Sem ruído, a MLP de score gera uma paisagem de perda com regiões de planura características de pontos de sela: o BLEU piora de 11,17 para 8,85 entre 30 e 100 épocas, enquanto os *spikes* de gradiente acumulam 177 ocorrências. Esse padrão — gradientes grandes mas sem progressão de qualidade — é consistente com o otimizador circulando ao redor de pontos de sela de baixa curvatura, oscilando violentamente sem encontrar direções de descenso estável. O ruído rompe essa circularidade: ao perturbar a trajetória, permite que o otimizador encon-

tre direções de descenso produtivo, como evidenciado pela redução de 93,2% nos *spikes* e pelo BLEU final de 19,51.

O Contraexemplo do Factorized Random Synthesizer

O *Factorized Random Synthesizer* constitui o experimento crucial que valida a explicação acima. Se o ruído fosse simplesmente um regularizador universal, ele deveria beneficiar todos os mecanismos. A queda de 44,7% no BLEU quando ruído é aplicado demonstra que o efeito é *mecanismo-dependente*.

A interpretação é direta: com pesos de atenção fixos e aleatórios, o único gradiente treinável flui pelas projeções de valor V . Essas projeções já operam em um contexto de atenção subotimal (pesos aleatórios), e perturbá-las via ruído de gradiente desequilibra um equilíbrio já frágil. Sem a possibilidade de melhorar os pesos de atenção (que são fixos), o ruído não pode promover exploração útil — apenas degrada a convergência das únicas projeções que poderiam compensar os pesos aleatórios.

Luong General: Dependência Crítica do Ruído

O caso do *Luong General Attention* ilustra o extremo oposto ao Factorized Random. A atenção multiplicativa com projeção W_a gera uma paisagem de perda extremamente acidentada quando inicializada aleatoriamente: sem ruído, o modelo colapsa em um mínimo trivial (0,47 BLEU, perplexidade 544), efetivamente não tradução nada compreensível. A interação cruzada decoder-encoder mediada por W_a cria dependências fortes entre camadas, amplificando qualquer instabilidade inicial.

Com ruído, o mecanismo atinge 17,51 BLEU em 100 épocas — competitivo com o Scaled Dot-Product sem ruído (18,91). Esta recuperação radical sugere que W_a possui uma região de boa qualidade no espaço de parâmetros, mas que a descida de gradiente padrão não consegue alcançá-la sem perturbação inicial para escapar do mínimo trivial. O ruído age como um mecanismo de *escape de colapso*: sua aplicação nas primeiras épocas (quando a variância é maior) é essencial para desviar o treinamento de trajetórias degeneradas.

Sensibilidade ao Nível de Ruído e Implicações Práticas

A ablação de σ no Scaled Dot-Product revela uma regra prática importante: **ruído pequeno em treinamentos longos é ótimo; ruído grande é sempre prejudicial**. O ponto ótimo ($\sigma = 0,01$) é três vezes menor que o nível utilizado com o Dense Synthesizer ($\sigma = 0,10$), sugerindo que cada mecanismo possui uma faixa ótima distinta. Em trabalhos futuros, a seleção automática de σ por validação deve ser tratada como hiperparâmetro essencial, não um detalhe de implementação.

Com base nos resultados, emergem quatro orientações práticas: *Scaled Dot-Product* com ruído para máxima qualidade (23,32 BLEU); *Dense Synthesizer* com ruído para o melhor equilíbrio qualidade/latência (19,51 BLEU, menor tempo de inferência); *Scaled Dot-Product* sem ruído em até 30 épocas para restrições computacionais severas (19,07 BLEU); e evitar, em qualquer cenário, *Factorized Random* com ruído (−44,7%) ou *Luong General* sem ruído (colapso para 0,47 BLEU).

Conclusão

Este trabalho investigou sistematicamente o efeito do ruído Gaussiano no gradiente sobre cinco famílias de mecanismos de atenção para NMT EN→FR, totalizando quinze configurações experimentais sob condições rigorosamente controladas. Os principais achados são:

1. O ruído beneficiou quatro dos cinco mecanismos investigados, com ganhos de +14,7% a +120,4% em SacreBLEU;
2. O *Scaled Dot-Product* com ruído alcançou o melhor resultado absoluto (BLEU 23,32, +23,3%) e redução de 68% nos *spikes* de gradiente (331→106);
3. O *Dense Synthesizer* exibe divergência progressiva sem ruído; com ruído, atinge BLEU 19,51 (+120,4%), eliminando 93,2% dos *spikes*;
4. O *Factorized Random Synthesizer* é o único contraexemplo: o ruído degrada o desempenho em -44,7%, demonstrando que o benefício da perturbação depende da existência de graus de liberdade treináveis na função de score;
5. O *Luong General Attention* colapsa sem ruído (0,47 BLEU), mas atinge 17,51 com ele — evidenciando que a perturbação pode ser condição necessária para viabilizar o treinamento de certos mecanismos.

A contribuição central deste trabalho é demonstrar que o ruído de gradiente não é um regularizador universal: seu efeito é fundamentalmente condicionado pela geometria da paisagem de perda induzida por cada função de score. Esta conclusão tem implicações diretas para o design de mecanismos de atenção e para a seleção de técnicas de regularização em treinamentos longos.

Trabalhos futuros podem explorar: (i) distribuições de ruído alternativas (uniforme, Laplace) e horários de decaimento adaptativos calibrados por mecanismo; (ii) combinação com *dropout* de atenção e outras formas de regularização; (iii) análise da paisagem de perda dos Synthesizers via visualização de perda [Li et al. 2018]; (iv) validação em outros pares linguísticos, domínios e escalas de dados.

Referências

- Bahdanau, D., Cho, K., and Bengio, Y. (2015). Neural machine translation by jointly learning to align and translate. In *Proceedings of the Third International Conference on Learning Representations*.
- Bhojanapalli, S., Yun, C., Rawat, A. S., Reddi, S. J., and Kumar, S. (2020). Low-rank bottleneck in multi-head attention models. In *Proceedings of the 37th International Conference on Machine Learning*, volume 119, pages 864–873. PMLR.
- Bojar, O. et al. (2014). Findings of the 2014 workshop on statistical machine translation. In *Proceedings of the Ninth Workshop on Statistical Machine Translation*, pages 12–58. Association for Computational Linguistics.
- Dauphin, Y. N., Pascanu, R., Gulcehre, C., Cho, K., Ganguli, S., and Bengio, Y. (2014). Identifying and attacking the saddle point problem in high-dimensional non-convex optimization. In *Advances in Neural Information Processing Systems*, volume 27.
- Koehn, P. (2005). Europarl: A parallel corpus for statistical machine translation. In *Proceedings of the Tenth Machine Translation Summit*, pages 79–86.

- Li, H., Xu, Z., Taylor, G., Studer, C., and Goldstein, T. (2018). Visualizing the loss landscape of neural nets. In *Advances in Neural Information Processing Systems*, volume 31.
- Loshchilov, I. and Hutter, F. (2019). Decoupled weight decay regularization. In *Proceedings of the Seventh International Conference on Learning Representations*.
- Luong, T., Pham, H., and Manning, C. D. (2015). Effective approaches to attention-based neural machine translation. In *Proceedings of the 2015 Conference on Empirical Methods in Natural Language Processing*, pages 1412–1421.
- Neelakantan, A., Vilnis, L., Le, Q. V., Sutskever, I., Kaiser, L., Kurach, K., and Martens, J. (2016). Adding gradient noise improves learning for very deep networks.
- Papineni, K., Roukos, S., Ward, T., and Zhu, W.-J. (2002). Bleu: a method for automatic evaluation of machine translation. In *Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics*, pages 311–318.
- Raganato, A., Scherrer, Y., and Tiedemann, J. (2020). Fixed encoder self-attention patterns in transformer-based machine translation. In *Findings of the Association for Computational Linguistics: EMNLP 2020*, pages 556–561.
- Sennrich, R., Haddow, B., and Birch, A. (2016). Neural machine translation of rare words with subword units. In *Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics*, pages 1715–1725.
- Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I., and Salakhutdinov, R. (2014). Dropout: A simple way to prevent neural networks from overfitting. *Journal of Machine Learning Research*, 15(1):1929–1958.
- Szegedy, C., Vanhoucke, V., Ioffe, S., Shlens, J., and Wojna, Z. (2016). Rethinking the inception architecture for computer vision. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 2818–2826.
- Tay, Y., Bahri, D., Metzler, D., Juan, D.-C., Zhao, Z., and Zheng, C. (2021). Synthesizer: Rethinking self-attention for transformer models. In *Proceedings of the 38th International Conference on Machine Learning*, volume 139 of *Proceedings of Machine Learning Research*, pages 10183–10192. PMLR.
- Tay, Y., Dehghani, M., Bahri, D., and Metzler, D. (2022). Efficient transformers: A survey. *ACM Computing Surveys*, 55(6):1–28.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., and Polosukhin, I. (2017). Attention is all you need. In *Advances in Neural Information Processing Systems*, volume 30. Curran Associates, Inc.
- Zhang, B., Williams, P., Titov, I., and Sennrich, R. (2020). Improving massively multilingual neural machine translation and zero-shot translation. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 1628–1639.